TP : Base de données MySQL, analyse avec Pandas et visualisation avec Matplotlib

Objectifs

— Créer une base de données et ses tables à partir d'un modèle logique.

— Manipuler un DataFrame Pandas : sélection, filtrage, valeurs manquantes.

— Échanger des données entre MySQL et Pandas (lecture, export CSV, écriture).

— Représenter des données avec Matplotlib, d'abord à partir de listes, puis à partir de résultats de requêtes SQL.

Mise en place de la base de données

Créez la base et les tables à partir du MLD suivant.

```
CLIENT (
    id_client [clé primaire]
)

ARTICLE (
    id_article [clé primaire],
    designation_article
)

COMMANDE (
    id_commande [clé primaire],
    date_commande,
    article [clé étrangère vers ARTICLE.id_article],
    client [clé étrangère vers CLIENT.id_client]
)
```

Une commande concerne un article et un client. Un client peut être associé à plusieurs commandes. Un article peut apparaître dans plusieurs commandes. Choisissez les types SQL et les contraintes adaptés, puis insérez quelques données de test.

1 Partie 1 : Manipuler un DataFrame

On dispose d'un tableau d'étudiants comportant les colonnes nom, note et âge, dont une valeur d'âge est manquante.

1. Créez le DataFrame et affichez-le. Indiquez son nombre de lignes et de colonnes.

2. Affichez les deux dernières lignes avec `tail`.

3. Avec `loc`, affichez le nom et la note de l'étudiant situé à l'index 1.

4. Affichez la ligne d'index 1 avec `loc`, puis les deux premières lignes et les deux premières colonnes avec `iloc`.

5. Expliquez la différence entre les sélections avec `loc` et `iloc`.

6. Sélectionnez les étudiants dont la note est supérieure à 10 et l'âge inférieur à 20. Affichez seulement leur nom et leur note.
7. Expliquez le rôle des parenthèses et de l'opérateur `&` dans ce filtre.
8. Affichez les noms des étudiants ayant une note supérieure à 10.
9. Définissez la colonne des notes comme index avec `set_index`, puis expliquez le résultat d'une sélection pour la note 15.
10. Comparez la sélection d'une seule colonne et celle d'une liste de colonnes. Quel type d'objet est retourné dans chaque cas ?
11. Repérez la valeur manquante. Affichez les valeurs manquantes avec Pandas et proposez une façon de les compter.

2 Partie 2 : MySQL et Pandas

A. Lecture et export

1. À l'aide de `pd.read_sql`, chargez dans un DataFrame le résultat d'une requête de votre choix portant sur la base créée.
2. Affichez le résultat de façon claire.
3. Expliquez les deux paramètres principaux transmis à `pd.read_sql` : la requête et la connexion.
4. Exportez le DataFrame en CSV avec le séparateur `;` et sans index.
5. Indiquez comment relire ce fichier CSV avec Pandas en précisant le bon séparateur.

B. Écriture en base

On considère la création d'un DataFrame suivie d'un appel à `to_sql`.

1. Expliquez le rôle des options `if_exists="append"` et `index=False`.
2. Décrivez le risque de relancer plusieurs fois une insertion en mode `append`.
3. Expliquez pourquoi une telle insertion doit être exécutée uniquement dans une base de test, après vérification des données et des droits d'accès.

C. Connexion

La connexion à MySQL se fait avec un moteur SQLAlchemy créé par `create_engine`.

1. Identifiez les paramètres nécessaires pour établir la connexion.
2. Expliquez le rôle du pilote `pymysql` dans l'URL de connexion.

3 Partie 3 : Matplotlib avec des listes

On dispose de trois listes : une liste de mois et deux listes de ventes (deux séries comparables). La figure est créée avec une grille de trois zones de graphique sur une ligne.

1. Indiquez ce que représente chacune des trois listes.
2. Expliquez ce que crée `plt.subplots(1, 3, figsize=(8, 4))`. Que retourne cette fonction ?
3. Tracez la première série dans la première zone, puis la seconde série dans la deuxième zone, sous forme de courbes.
4. Combien de zones de graphique sont créées ? Combien sont effectivement utilisées ?
5. Ajoutez à chaque zone utilisée un titre, une étiquette pour l'axe horizontal et une étiquette pour l'axe vertical.

6. Ajoutez une légende permettant d'identifier chacune des deux séries.
7. Expliquez pourquoi la troisième zone reste vide.
8. Affichez la longueur de l'objet contenant les zones, le nombre d'attributs et méthodes (`dir`) de cet objet et d'une de ses zones, ainsi que sa taille (`size`). Expliquez brièvement ce que chaque affichage permet d'observer.
9. Proposez une modification pour obtenir une disposition correspondant exactement au nombre de graphiques souhaités.

4 Partie 4 : Visualiser les résultats MySQL

On dispose d'un programme qui exécute deux requêtes SQL, charge leurs résultats dans deux DataFrames et trace quatre graphiques dans une grille de 2×2 zones.

A. Comprendre le flux du programme

1. Décrivez le rôle de chacune des deux requêtes SQL.
2. Expliquez comment les résultats des requêtes sont chargés dans les DataFrames.
3. Indiquez quelles colonnes de chaque DataFrame sont utilisées pour les graphiques.
4. Expliquez le rôle de `plt.subplots(2, 2, figsize=(12, 6))` et identifiez les quatre zones de graphique.
5. Associez chaque zone à son type de graphique : courbe, barres, histogramme ou nuage de points.
6. Pour chaque graphique, proposez un titre et des noms d'axes adaptés aux données affichées.

B. Vérifier les calculs et les dimensions

1. Dans la requête qui relie plusieurs tables, repérez les tables de la clause `FROM` et les conditions de la clause `WHERE`.
2. Vérifiez si chaque table possède une condition de jointure. Quelle est la conséquence possible d'une condition manquante ?
3. Expliquez ce que calcule `COUNT` sur l'identifiant d'article. Est-ce nécessairement le nombre d'unités vendues ?
4. Expliquez pourquoi une liste de clients saisie « en dur » dans le programme est risquée : que se passe-t-il si sa longueur diffère de celle de la série à laquelle on l'associe ?
5. Comparez les dimensions des séries tracées sur un même graphique. Que faut-il vérifier avant d'appeler `plot` ?
6. Proposez une requête qui compte les commandes par date.
7. Réécrivez la requête des ventes par article avec une jointure explicite `JOIN ... ON`. Vérifiez les noms de colonnes dans le schéma MySQL avant de choisir vos conditions.

C. Améliorer les figures

1. Ajoutez une légende aux séries réellement tracées, en associant chaque étiquette directement à sa série plutôt qu'à l'ordre d'une liste séparée.
2. Ajoutez un titre et des étiquettes d'axes aux quatre graphiques.
3. Vérifiez que le graphique en barres commence à zéro.
4. Vérifiez que le nuage de points compare deux séries de même longueur et de types adaptés.
5. Enregistrez la figure finale dans un fichier image, après avoir vérifié que le dossier choisi existe.